

Earth Agent: 基于大语言模型的 Google Earth Engine 智能代理系统

系统设计、闭环交互与 UnivEARTH 评测

Xiaokang Fu

2026-04-25

Google Earth Engine (GEE) 是当前应用最广泛的云端地理空间分析平台

痛点：

- 复杂的 JavaScript / Python API
- 上千个数据集与函数，学习成本高
- 调试链路冗长（写代码 → 跑 → 看 console → 修 → 再跑）
- 多步骤分析任务需要熟悉 GEE 内部机制

机会：大语言模型在代码生成与工具调用上取得突破，为自然语言驱动的地理空间分析提供新可能

Earth Agent 是什么

一个 **Chrome** 浏览器扩展 + **MCP** 服务器，把 LLM 代理范式引入 GEE 在线编辑器

两种使用方式：

1. **扩展独立使用**：自带聊天面板，直接对话操作 GEE
2. **MCP 接入外部 AI**：让 Claude Code、Cursor、Zed 等编辑器通过 MCP 协议直接调用 GEE 工具

关键创新：闭环交互 (closed-loop)

- 不仅生成代码，还能 **执行 → 观察结果 → 修正**
- LLM 直接感知 GEE 运行环境（控制台、地图、Inspector）
- 实现自主的多步骤地学分析 workflows

已上线 **Chrome Web Store** + 开源

系统架构



LLM 不只是“代码生成器”，而是真正的“代理人”：

能力	工具
写代码	<code>writeCode</code> 、 <code>editCode</code>
跑代码	<code>runCurrentCode</code>
读控制台	<code>getConsoleOutput</code>
看地图	<code>screenshot</code> （多模态视觉）
查文档	<code>geeDocs</code> (GEE Datasets + API)
点要素	<code>clickAtScreenPosition</code> 、 <code>Inspector</code>

典型流程 (agent 自主完成)：

用户：“*Medina* 城市从 1984 到 2018 是否扩张？”Agent：查 GEE 数据集 → 写 *Landsat* 计算代码 → 跑 → 读控制台 → 数字看起来不对 → 截图地图验证 → 改方法 → 再跑 → “ANSWER: Yes”

方法论护栏 (Methodology Guardrails)

为提升地学任务质量，引入 7 条领域知识作为系统级 prompt：

1. 数值合理性校验：极端值要重新检查方法
2. 跨传感器可比性：避免 Landsat 5/8 NDBI 直接比较
3. 优先成熟产品：JRC GSW、MCD12Q1、GHSL 等
4. 干旱区识别：NDBI 在沙漠不可靠 → 用夜光数据
5. 避免任意阈值：单一阈值要溯源 + 敏感性测试
6. 空间可视化验证：可疑结果用截图核实
7. **GEE 限额内**：禁止 `Export.*`，控制 `scale/bestEffort`

作用：通过 Chrome Extension 的 Custom Instructions 注入，不修改 benchmark prompt (避免 overfitting)

数据集：UnivEARTH (Sun et al., 2024) —140 道 Yes/No 地球观测题

13 个标签：Air Pollution, Climate, Cloud & Fog, Fire, Landuse, Precipitation, Snow, Soil Moisture, Temperature, Urban & City, Vegetation, Water, Water Color

两种评测方式：

- **Type 1** (Internal)：扩展自带 AgentTestPanel 批量跑
- **Type 2** (External)：通过 MCP 让外部 AI 编辑器跑

本次报告：**Type 1**，分层抽样 **13** 题（每个标签 **1** 题，固定随机种子）

已确保可复现性：git SHA、模型版本、Custom Instructions SHA256、抽样种子全部快照

模型：


- Smoke test: Haiku 4.5 / Sonnet 4.6 / Opus 4.7 (5 题对比)
- 主实验: Claude Opus 4.7 (13 题分层抽样)

关键工程优化：

- AI SDK v6 prompt caching (system + tools, 1h TTL)
- `experimental_repairToolCall`: 自动修复畸形 JSON 工具调用
- 截图 JPEG quality 60 (兼容 Helicone 日志)
- `stepCounts(100)`: 允许深度推理链

遥测：所有 LLM 调用通过 Helicone 记录，包括 token、cost、tool call 链路

结果 1: Opus 4.7 在 stratified_13 上达成 92.3%



结果 2: 13 个标签的覆盖




Figure 2: 13 标签 × Opus 4.7 准确率

12/13 标签满分 (深绿 = 1.00), 仅 Vegetation 一题失分

结果 3：跨模型对比 (5 题 smoke test)




Figure 3: 三模型在 5 题 smoke test 上的表现

结果 4: 相比 UnivEARTH 论文 baseline 的飞跃




Figure 4: Earth Agent (Opus 4.7) vs UnivEARTH paper baselines

- 论文最强 baseline (DeepSeek-V3): ~32% 准确率
- 论文最强 baseline 失败率: 均 > 60%
- **Earth Agent + Opus 4.7: 92.3% 准确率, 0% 失败率**

讨论：能力提升来自何处？

1. 闭环工具链：执行 → 观察 → 修正 弥补单次代码生成的不足
2. 多模态视觉验证：截图工具让 agent 能像人类一样核实地图结果
3. 方法论 **guardrails**：跨传感器、干旱区、合理性校验等领域知识
4. 更强的 **LLM**：Opus 4.7 推理能力 + tool use 稳定性
5. **prompt caching**：使长链路 tool 调用经济可行

关键洞见：选择性准确率始终为 100%，说明失败模式主要是基础设施问题（连接断、API 过载），而非模型推理错误

问题	解决
Service Worker 30s 终止	keep-alive ping + chrome.alarms
Anthropic 偶发畸形 tool JSON	experimental_repairToolCall 兜底
Helicone 大请求 body 丢失	PNG → JPEG quality 60
Claude 4.6+ 拒绝 temperature	自动检测并删除参数
跨模型成本差异巨大	Sonnet/Haiku 跑全集 + Opus 跑困难子集策略

全部修复均已 **commit** 到主分支

1. **完整 140 题评测**: 扩展到全 UnivEARTH 数据集
2. **Type 2 (MCP) 评测**: 对比扩展自带 vs 外部编辑器调用
3. **多模型矩阵**: GPT-5.4 / Gemini 3.1 / DeepSeek-V3 同台对比
4. **Reflexion / few-shot**: 反思与示例对失败题的补救能力
5. **Custom Instructions 消融实验**: 量化 guardrails 的边际收益
6. **细粒度任务难度梯度**: 从单步查询到多步分析

Earth Agent:

- 首个专为 GEE 设计的闭环 LLM 代理系统
- Chrome 扩展 + MCP 双形态, 已开源、已上架
- 方法论 guardrails 让通用 LLM 适配地学领域

评测:

- Opus 4.7 在 UnivEARTH 分层子集达到 **92.3%** 准确率, **0%** 失败率
- 相比 UnivEARTH 论文最强 baseline (~32%) 提升约 3 倍
- 选择性准确率 100% 说明失败几乎都是工程问题, 非推理错误

意义: 证明配备工具链与领域护栏的 LLM 代理 可以胜任真实的多步地学分析 workflows

致谢 & 开源链接: GitHub:

<https://github.com/Davidxswang/earth-agent-ai-sdk>

谢谢!

Q&A

GitHub: <https://github.com/Davidxswang/earth-agent-ai-sdk>

Chrome Web Store: 搜索“Earth Agent”NPM: `earth-agent-mcp`